

Assistant Académique IA – HEC / Polytechnique

Document de travail – Discussion technique & stratégique

1. Vision & Philosophie

L'objectif n'est pas de créer un simple chatbot conversationnel, mais un agent académique institutionnel, structuré, gouverné, traçable et évolutif.

Principes directeurs :

- Architecture LLM-agnostique (pas de dépendance fournisseur, possibilité d'A/B testing)
- Approche RAG prioritaire (réponses fondées sur des sources)
- Validation humaine (human-in-the-loop)
- Conception institution-ready (logs, permissions, gouvernance)

2. Démo actuelle – Fonctionnalités existantes

Architecture :

- Pipeline RAG
- Base vectorielle
- Interface web
- Données publiques institutionnelles
- Score de confiance
- Système de feedback utilisateur

Fonctionnalités :

- Questions sur règlements académiques
- Deadlines publiques
- Structure des programmes
- Recherche sémantique multi-documents

- Citation des sources
- Détection des réponses à faible confiance

3. Stack technique cible

Frontend :

- Next.js (App Router)
- Tailwind CSS

Backend :

- Node.js (API routes)
- Validation stricte (Zod)
- Middleware de rate limiting

Base de données :

- PostgreSQL
- Extension pgvector
- Row-Level Security (RLS)

Couche RAG :

- LlamaIndex
- Recherche hybride (BM25 + vector search)

Couche LLM :

- Interface abstraite LLMProvider
- Implémentations OpenAIProvider / GeminiProvider
- Provider unique pour embeddings

Authentification :

- Phase 1 : Magic link
- Phase 2 : Intégration Azure AD / Microsoft Entra ID

Observabilité :

- Logs structurés
- Dashboard analytics
- Monitoring latence et coût

4. Fonctionnalités futures

Court terme :

- Back-office administrateur
- Import documents (PDF/DOCX/URL)
- Workflow Draft → Publish
- Dashboard analytics

Moyen terme :

- Authentification Microsoft
- Table deadlines structurée (SQL)
- Synchronisation calendrier (ICS)

Avancé :

- Agents autonomes supervisés
- Moteur de suggestion FAQ
- Clustering des questions récurrentes
- Digest hebdomadaire pour l'administration

5. Blocages identifiés

- Validation intégration Azure AD
- Accès aux API internes
- Gouvernance éditoriale
- Clarification conformité RGPD
- Positionnement institutionnel (officiel ou expérimental)

6. Besoins de collaboration

Technique :

- Optimisation avancée du RAG
- Sécurisation production-grade

Institutionnel :

- Accès API
- Intégration Azure AD
- Validation gouvernance des données

Stratégique :

- Cadre Hi! PARIS
- Structuration inter-écoles